

소비기한 OCR 추출 파이프라인

[DScover] C조

입력: 상품 뒷면 이미지 (환경변수 `ITDA_INPUT_DIR` 로 경로 주입)



1 전처리

이미지 로드(한글 경로 대응) → 640px로 리사이즈. 속도·정확도 실험으로 확인한 값 (960px 이상은 정확도 향상 없이 처리 시간만 증가)



2 OCR 엔진 — PaddleOCR^[1]

검출(Detection): PP-OCRv5_server_det · 인식(Recognition): korean_PP-OCRv5_mobile_rec
40장 벤치마크에서 EasyOCR^[2] 대비 정확도 2배 이상(35% vs 15%) 확인 후 채택. 채점 서버가 인터넷 차단 환경임을 확인하여 가중치를 저장소에 로컬화(`download_weights.sh`)하고 오프라인 실행 검증 완료



3 핵심 판별 로직 — "여러 날짜 후보 중 진짜 소비기한 골라내기"

- 3-1 같은 줄 병합: OCR이 한 줄짜리 날짜를 여러 조각으로 쪼개 인식하는 문제 보정 (예: "2022" / "02.14" → "2022.02.14")
- 3-2 앵커 키워드 탐색: "유통기한"/"소비기한"/"까지" 근처 날짜를 최우선 채택 (같은 줄 위치 우선)
- 3-3 부정 키워드 필터: "제조일자"/"소분일"/"포장일"/"부터"(시작일) 등 다른 종류의 날짜는 후보에서 제외
- 3-4 Fallback — 최댓값 채택: 앵커로 못 찾으면 유효 날짜 후보 중 가장 늦은 날짜 채택 (소비기한은 항상 제조일보다 미래라는 도메인 규칙 활용)
- 3-5 부분점수 대응: 완전한 날짜가 없어도 앵커 근처에서 연+월 또는 월+일만이라도 채택 (연/월/일 개별 채점 규칙 확인 후 반영)



4 제출 파일 저장

submission.csv — image_id, year, month, day, final_date (미인식 필드는 개별 NONE, 전부 미인식 시 final_date 만 단일 NONE)

1. 설계 논리 — 기술 선택의 근거

데이터 실측 기반 개발

- 모든 설계 결정을 추측이 아닌 **직접 라벨링한 검증셋(587장)**으로 검증. 초반 40장 무작위 샘플은 통계적 노이즈($\pm 7\%$)가 커서 신뢰 불가함을 확인, 표본을 지속적으로 확대해 재현 가능한 판단 기준을 확보함
- 효과 없거나 오히려 악화된 시도(CLAHE 대비 향상, 크롭 재인식, 탐지 민감도 조정, 회전 보정 등)도 전부 실측 후 기각 — "왜 이 방법을 안 썼는지"까지 근거 확보

엔진 선택 — EasyOCR → PaddleOCR

- 속도 제약을 3,352장/40분으로 오인해 EasyOCR(경량)로 시작했으나, 채점 기준이 **500장/40분(장당 예산 약 7배 여유)**임을 재확인한 뒤 재계산 → 동일 예산 안에서 PaddleOCR이 정확도 2배 이상 높음을 실측, 전환

판별 로직에 개발 역량을 집중한 이유

- 실패 사례를 직접 분석한 결과, recall 저하의 핵심 원인은 OCR 탐지 실패보다 **"여러 날짜 후보 중 소비기한을 정확히 골라내는 판단"**에 있었음 (제조일자·소분일과의 혼동, 시작일/종료일 쌍 오판 등) — 그래서 모델 자체보다 후처리 규칙 엔진에 집중 투자
- 날짜 정규식이 연도 우선(YYYY.MM.DD) 형식만 가정하고 있어 수입상품 표기(유럽식 DD.MM.YYYY, 영문 월 이름)를 다수 놓치고 있음을 발견 — 다국가 표기 지원으로 확장한 단일 개선으로 recall이 10%p 이상 향상됨
- confidence 점수는 정답/오답 판별에 사용할 수 없음을 실측으로 확인(오답의 confidence가 정답보다 높은 사례 존재) — 규칙 기반(영 커 키워드·부정 키워드) 판별로 대체

2. 제한된 CPU 환경 최적화 전략

- 채점 환경:** Standard 4-Core vCPU, GPU 없음, 인터넷 차단(오프라인) — 500장/40분 예산
- 속도 확보:** 이미지 리사이즈 640px로 고정. 960px로 올려도 정확도 향상은 없고 처리 시간만 늘어남을 실측 확인하여 640px를 속도·정확도 균형점으로 확정
- 오프라인 실행 대응:** 채점 서버가 인터넷 차단 환경임을 확인한 뒤, 모델 가중치를 `download_weights.sh` 로 로컬화하고 PaddleX의 온라인 연결 확인 단계까지 비활성화 — 네트워크 완전 차단 상태에서 `predict.ipynb` 전체 실행이 통과하는 것을 직접 검증함
- 오탐(정밀도) 관리:** 탐지 민감도를 높이는 시도는 전부 정밀도 저하로 이어짐을 확인하고 채택하지 않음 — "확신 없으면 NONE" 원칙을 유지해 정밀도 89%를 확보

78.0%

필드 단위(연/월/일) 정답률
587장 검증셋 기준

89%

정밀도(Precision)
답을 낸 것 중 정답 비율

≈25분

500장 처리 예상 시간
(예산 40분)

3. 활용 방안 및 확장성

- 실무 적용:** 편의점·마트 재고관리 시스템에 임베드하여 유통기한 임박 상품 자동 알림 및 폐기 시점 예측을 통한 손실 절감에 활용 가능
- 탐지 모델 고도화:** 현재 남은 실패의 상당수가 순수 OCR 탐지 실패(회전·저대비·특수 인쇄 스타일)이므로, 바운딩박스 라벨을 추가로 구축해 검출 모델 자체를 파인튜닝하는 것이 다음 개선 방향
- 하이브리드 운영 모델:** 저신뢰도 케이스에 한해 사람 검수를 트리거하는 구조로 확장하면, 완전 자동화 환경에서도 정밀도-재현율 균형을 실무 수준으로 끌어올릴 수 있음
- 부분 정보의 실무 활용:** 본 파이프라인이 지원하는 "연도까지만 아는 경우" 등 부분 인식 결과도, 실제 운영에서는 보수적 폐기 임박 경고 등에 활용 가능

참고문헌 [1][2] 상세 출처는 GitHub 저장소 README.md 하단 참고